



UNIVERSIDAD
SANTO TOMÁS

PRESENTACIÓN



**Ingeniero Electrónico, Magister en Ingeniería con
énfasis en electrónica y estudiante del doctorado en
ingeniería con énfasis en eléctrica y electrónica de la
UDFJC**

Diego Alejandro Barragán Vargas

**Docente de electrónica Universidad Santo Tomás de
Aquino**

Enlace de Interés:

<https://scholar.google.com/citations?hl=es&user=Bp3QMQMAAAAJ>



UNIVERSIDAD
SANTO TOMÁS

Sesión 6-Árboles de Búsqueda

4 de Septiembre, Bogotá D.C.

CONTENIDO

TEXTO COMPLEMENTARIO

Árboles de Búsqueda Informada



Heurísticas



Greedy



Search



A* (Consistencia y
Admisibilidad)



Algoritmos de Búsqueda Informada

Los algoritmos de búsqueda informada en IA son métodos de búsqueda que utilizan conocimiento adicional, llamado heurística, para priorizar las rutas a explorar.

C
A
R
A
C
T
E
R
Í
S
T
I
C
A
S

Al estimar la proximidad de cada paso al objetivo, estos algoritmos pueden encontrar soluciones con mayor rapidez y eficiencia que la búsqueda desinformada o a ciegas.

Se utilizan ampliamente en IA para tareas como la búsqueda de rutas y la resolución de acertijos, ya que ayudan a navegar por espacios de búsqueda amplios y complejos.

Estos algoritmos priorizan las rutas que parecen más prometedoras hacia el objetivo, usando una función de evaluación para estimar el costo de llegar al estado deseado.

Algoritmos Heurísticos

Un algoritmo heurístico es un método de búsqueda o solución de problemas que no garantiza encontrar la solución óptima, pero sí proporciona una solución suficientemente buena en un tiempo razonable.

Se usan
cuando:

El espacio de búsqueda es demasiado grande.

Los algoritmos exactos serían muy lentos o inviables.

Es preferible una buena solución rápida a una solución óptima muy costosa.

Características:

Aproximación

No siempre encuentran la mejor solución, pero logran soluciones de calidad aceptable.

Rapidez:

Reducen el tiempo de cómputo comparado con algoritmos exactos.

Flexibilidad:

Se adaptan a distintos problemas.

Basados en reglas de experiencia

Usan conocimiento previo, intuición o reglas empíricas.

Escalabilidad

Funcionan bien en problemas grandes donde otros algoritmos colapsarían.

Funcionamiento



```
graph TD; A[Definir el Problema  
(Función Objetivo,  
restricciones)] --> B[Usar Estrategia  
Heurísticas (Regla de  
Decisión)]; B --> C[Evaluar las  
Soluciones  
Encontradas]; C --> D[Iterar hasta lograr una solución  
suficientemente buena o  
cumplir un criterio de parada.];
```

The diagram illustrates the functioning of a heuristic algorithm through a four-step process. It begins with a yellow banner labeled 'Funcionamiento'. The first step, 'Definir el Problema (Función Objetivo, restricciones)', is in an orange box. An arrow leads to the second step, 'Usar Estrategia Heurísticas (Regla de Decisión)', in a blue box. Another arrow leads to the third step, 'Evaluar las Soluciones Encontradas', in a green box. A final arrow leads to the fourth step, 'Iterar hasta lograr una solución suficientemente buena o cumplir un criterio de parada.', in a grey box.

Definir el Problema
(Función Objetivo,
restricciones)

**Usar Estrategia
Heurísticas** (Regla de
Decisión)

**Evaluar las
Soluciones
Encontradas**

**Iterar hasta lograr una solución
suficientemente buena o
cumplir un criterio de parada.**

Tipos de Algoritmos Heurísticos

Búsqueda local

Exploran soluciones cercanas a la actual.

Ejemplo: Hill Climbing (ascenso de colina), Simulated Annealing (enfriamiento simulado).

Ejemplo: Búsqueda Local – Hill Climbing

```
import random

def f(x):
    return -(x-3)**2 + 9 # Máximo en x=3

def hill_climbing(iteraciones=1000):
    x = random.uniform(-10, 10) # punto inicial aleatorio
    for _ in range(iteraciones):
        nuevo_x = x + random.uniform(-1, 1) # pequeña variación
        if f(nuevo_x) > f(x):
            x = nuevo_x
    return x, f(x)
```

Maximizar la función

$$f(x) = -(x - 3)^2 + 9.$$

Encuentra un valor cercano a $x=3$ aunque no siempre exacto.

Metaheurísticas

Estrategias más generales que combinan heurísticas simples.

Ejemplo: Algoritmos genéticos, Colonia de hormigas, Enjambre de partículas.

Algoritmo Genético sencillo

```
import random

def fitness(x):
    return x**2

def mutacion(x):
    return x ^ (1 << random.randint(0, 4)) # muta un bit

def algoritmo_genetico(generaciones=50, poblacion_size=6):
    poblacion = [random.randint(0, 31) for _ in range(poblacion_size)]
    for _ in range(generaciones):
        poblacion = sorted(poblacion, key=fitness, reverse=True)
        nueva_poblacion = poblacion[:2] # elitismo
        while len(nueva_poblacion) < poblacion_size:
            padre = random.choice(poblacion[:3])
            hijo = mutacion(padre)
            nueva_poblacion.append(hijo)
        poblacion = nueva_poblacion
    mejor = max(poblacion, key=fitness)
    return mejor, fitness(mejor)

sol = algoritmo_genetico()
print("Mejor solución:", sol)
```

Maximizar la función

$$f(x) = x^2 \text{ en } [0, 31].$$

El algoritmo evoluciona soluciones y encuentra valores cercanos al óptimo

Greedy (voraces)

Toman decisiones locales óptimas esperando llegar a una solución global aceptable.

Ejemplo: Algoritmo de Dijkstra (camino más corto).

Algoritmo Greedy (Cambio de monedas)

```
def cambio_monedas(cantidad, monedas=[50, 20, 10, 5, 1]):  
    resultado = []  
    for moneda in monedas:  
        while cantidad >= moneda:  
            cantidad -= moneda  
            resultado.append(moneda)  
    return resultado  
  
print("Cambio para 87:", cambio_monedas(87))
```

Elige siempre la moneda más grande posible primero (decisión voraz).

Para 87.

87 → [50, 20, 10, 5, 1, 1]

Características	Heurísticas clásicas	Metaheurísticas
Idea principal	Reglas simples/greedy o mejoras locales que usan conocimiento directo del problema.	Estrategias generales inspiradas en procesos naturales/sociales que exploran el espacio de búsqueda combinando exploración y explotación.
Alcance de búsqueda	Principalmente local (p. ej. greedy, hill-climbing).	Típicamente global (buscan escapar de óptimos locales).
Exploración vs Explotación	Fuerte explotación (decisiones locales); poca exploración.	Balance explícito entre exploración y explotación (mecanismos de diversidad).
Garantía de óptimo	No garantizan óptimo global; pueden ser deterministas y converger rápido.	Tampoco garantizan óptimo global, pero tienen mayor probabilidad de encontrar soluciones cercanas al global.
Uso de memoria	Baja (sin memoria o mínima).	Pueden usar memoria (p. ej. feromonas en ACO, mejores soluciones históricas en PSO, poblaciones en GA).
Operadores típicos	Reglas voraces, intercambio local, evaluación de vecinos.	Crossover/mutación (GA), movimiento por velocidad (PSO), feromonas & probabilidad (ACO), selección de fuentes (ABC), etc.
Complejidad computacional	Baja por iteración; muchas iteraciones pueden ser rápidas.	Más costosas por iteración (poblaciones/colonos/enjambres); pero convergen mejor en problemas grandes.
Ventajas	Fáciles de entender/implementar; rápidas para soluciones aceptables.	Flexibles, robustas para problemas complejos, adaptables a distintos dominios.
Desventajas	Se atascan en óptimos locales; dependen mucho de la solución inicial.	Requieren ajuste de hiperparámetros; mayor coste computacional.
Aplicaciones típicas	Asignación simple, heurísticas de construcción (ej. knapsack approximations), greedy para scheduling.	Optimización combinatoria y continua (TSP, diseño, redes, machine learning hyperparam tuning, planificación).
Ejemplos	Hill Climbing, Greedy, Búsqueda en primer mejor.	Algoritmos Genéticos (GA), Particle Swarm Optimization (PSO), Ant Colony Optimization (ACO), Artificial Bee Colony (ABC).

Algoritmo Genético sencillo

Es una técnica de optimización y búsqueda basada en la evolución natural. Simula cómo los individuos (soluciones) evolucionan generación tras generación aplicando selección, cruce (crossover) y mutación para encontrar soluciones cada vez mejores.

Breve Historia

Los algoritmos genéticos se inspiran en la teoría de la evolución de Charles Darwin (selección natural y supervivencia del más apto).

Fueron propuestos en los años 60–70 por John Holland en la Universidad de Michigan.

Su idea central era utilizar los principios de la biología (mutación, cruce, selección) para resolver problemas complejos de optimización y búsqueda.

Posteriormente, en los años 80–90, se aplicaron en inteligencia artificial, optimización combinatoria, ingeniería, bioinformática, control y finanzas.

Ventajas

No necesita derivadas ni gradientes

Explora grandes espacios de búsqueda

Es paralelizable lo que permite la ejecución de múltiples núcleos y máquinas.

Es flexible, porque se adapta a diferentes problemas de optimización, clasificación, etc.

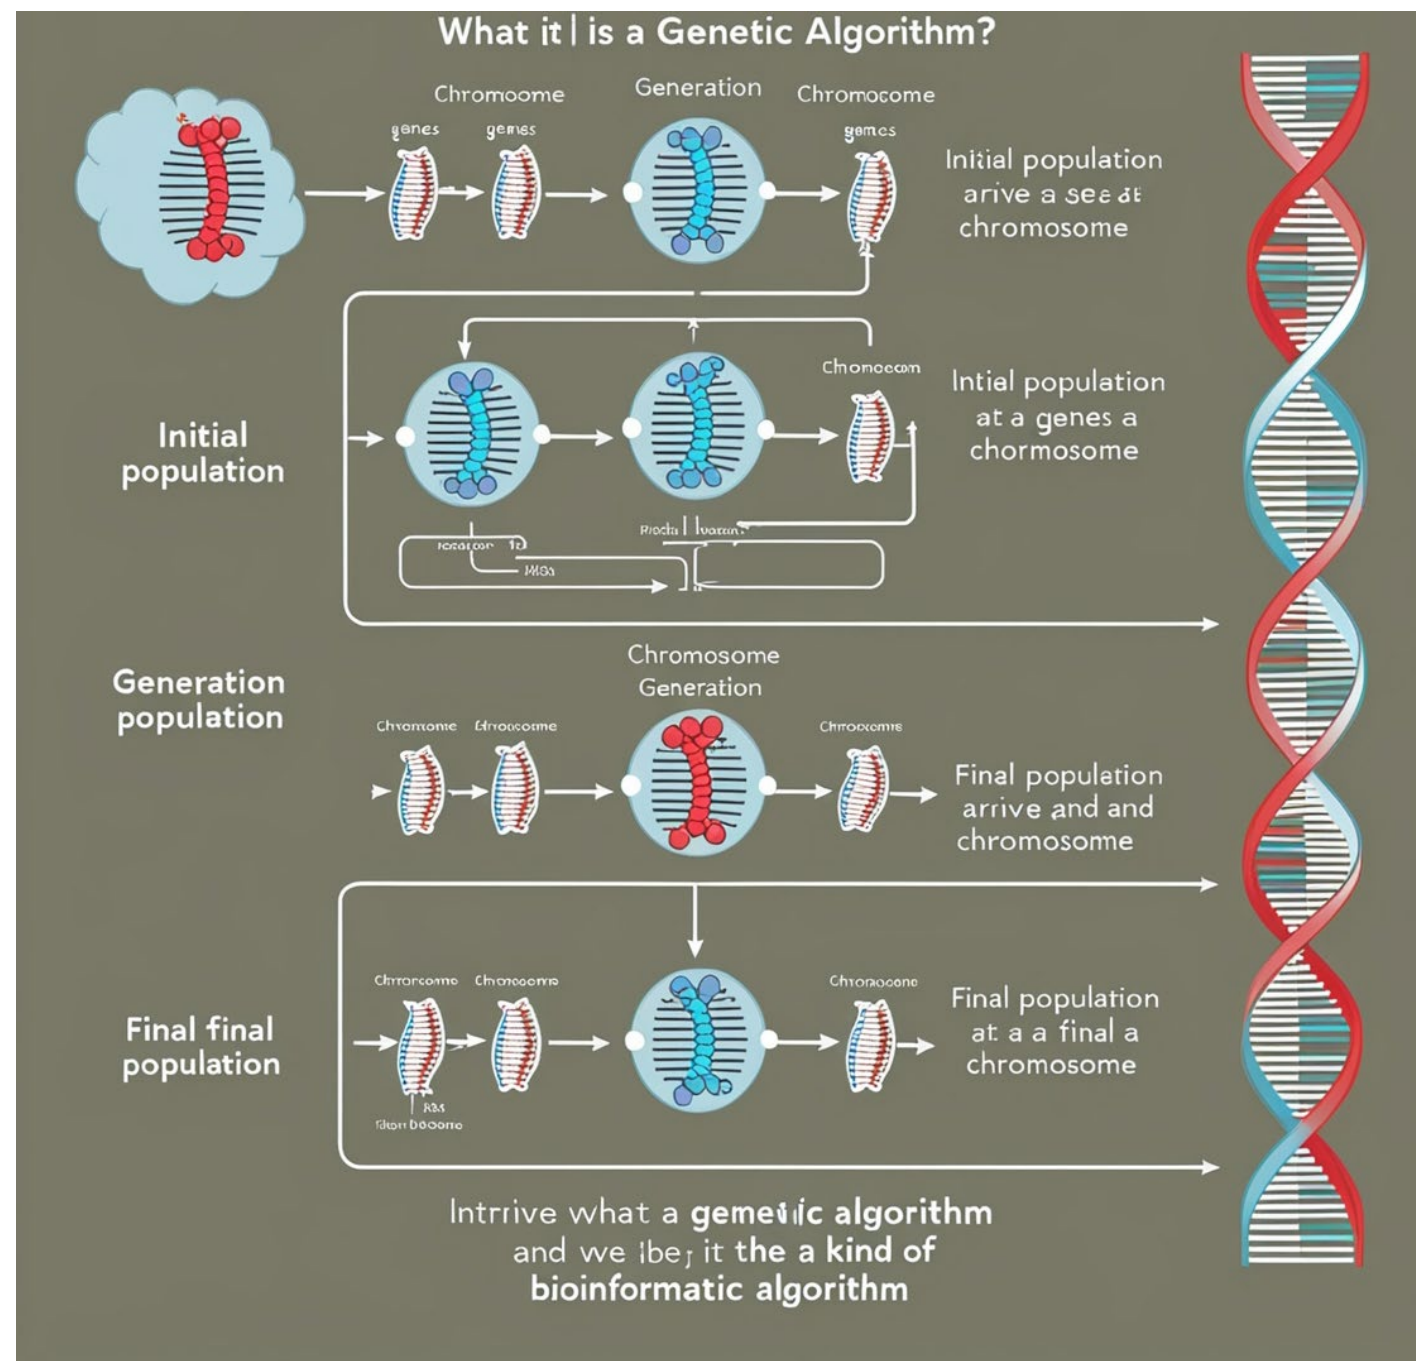
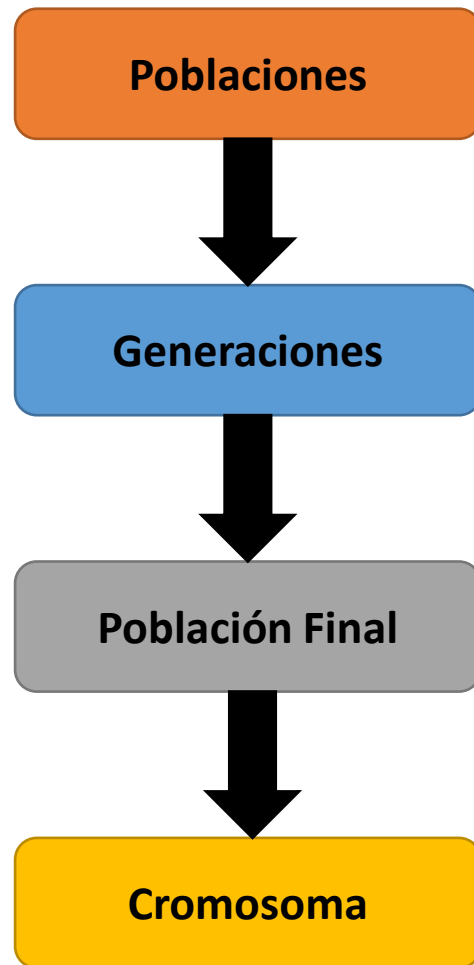
Desventajas

Alto costo computacional.

No garantizan la mejor solución.

Parámetros sensibles, dado que el rendimiento depende del tamaño de la población.

Puede tener una convergencia lenta en algunos problemas.



Fuente: Leonardo AI



UNIVERSIDAD
SANTO TOMÁS

GRACIAS